Vícerozměrné náhodné veličiny, generování vícerozměrných veličin

Marek Ondriáš | Vitalij Atamanjuk

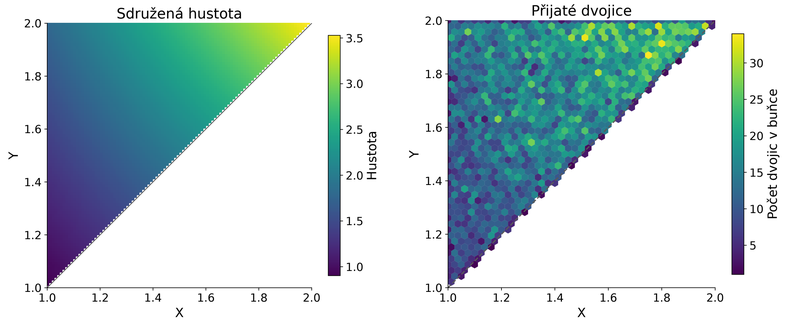
FAKULTA APLIKOVANÝCH VĚD ZÁPADOČESKÉ UNIVERZITY V PLZNI

KATEDRA MATEMATIKY

01 Model a cíl programu

Odvodit charakteristiky spojitého vektoru (X, Y), vygenerovat závislé dvojice a porovnat výběrové odhady s teorií.

$$f(x,y) = \begin{cases} cxy, & 1 < x < y < 2, \\ 0, & \text{jinak.} \end{cases} \qquad 1 = c\int_1^2\int_x^2 xy\,\mathrm{d}y\,\mathrm{d}x = c\frac{9}{8} \quad \Rightarrow \quad \boxed{c = \frac{8}{9}}.$$



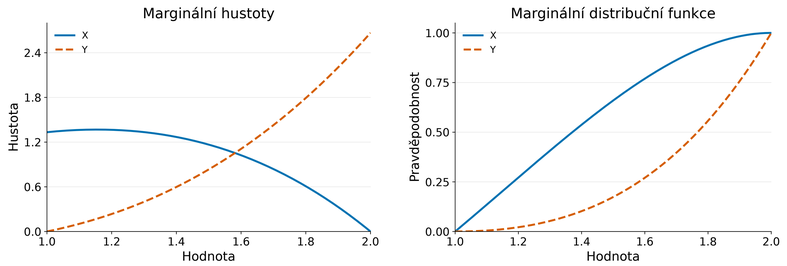
Vlevo sdružená hustota; vpravo počty přijatých dvojic v šestiúhelnících. Trojúhelníková podpora vynucuje $X < Y$.

02 Marginální rozdělení

Pro $1 < t < 2$ dostáváme integrací sdružené hustoty:

$$f_X(t) = \frac{4}{9}t(4 - t^2),\ F_X(t) = \frac{-t^4 + 8t^2 - 7}{9},$$
$$f_Y(t) = \frac{4}{9}t(t^2 - 1),\ F_Y(t) = \frac{(t^2-1)^2}{9}.$$

Mimo $(1, 2)$ jsou hustoty nulové. Distribuční funkce mají hodnotu 0 pro $t \le 1$ a 1 pro $t \ge 2$.



03 Teoretické charakteristiky

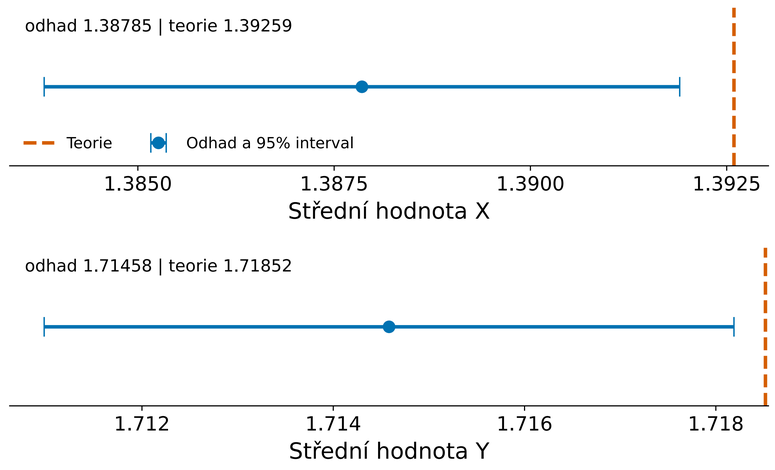
$$\boldsymbol{\mu} = \begin{pmatrix} 188/135 \\ 232/135 \end{pmatrix}, \qquad \boldsymbol{\Sigma} = \frac{1}{18225}\begin{pmatrix} 1106 & 484 \\ 484 & 851 \end{pmatrix}.$$

Závislost: $\mathrm{Cov}(X, Y) = 0.02656 > 0$. Vyšší hodnoty X se pojí s vyššími hodnotami Y; nenulová kovariance vylučuje nezávislost.

04 Generování a bodové odhady

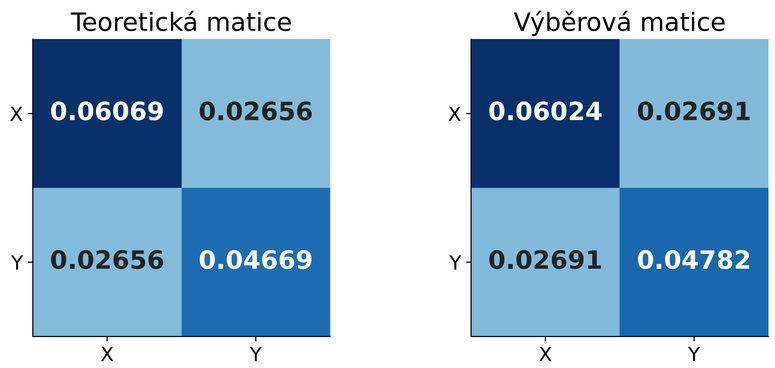
Zamítací metoda: nezávisle navrhujeme $U, V \sim U(1, 2)$ a $Z \sim U(0, 32/9)$. Dvojici přijmeme, právě když $U < V$ a $Z \le \frac{8}{9}UV$.
Z $50\,000$ návrhů vzniklo $n = 14\,130$ **dvojic**. Úspěšnost $28.26\,\%$ odpovídá teorii $9/32 = 28{,}125\,\%$. Použit je pevný seed 42.

05 Střední hodnoty a intervalové odhady



Body: výběrové průměry; úsečky: 95% intervaly se Studentovým kvantilem; přerušované čáry: teorie. Každý řádek má vlastní osu. Pro nenormální marginály jde o asymptotické přiblížení.

06 Rozptyly a kovariance



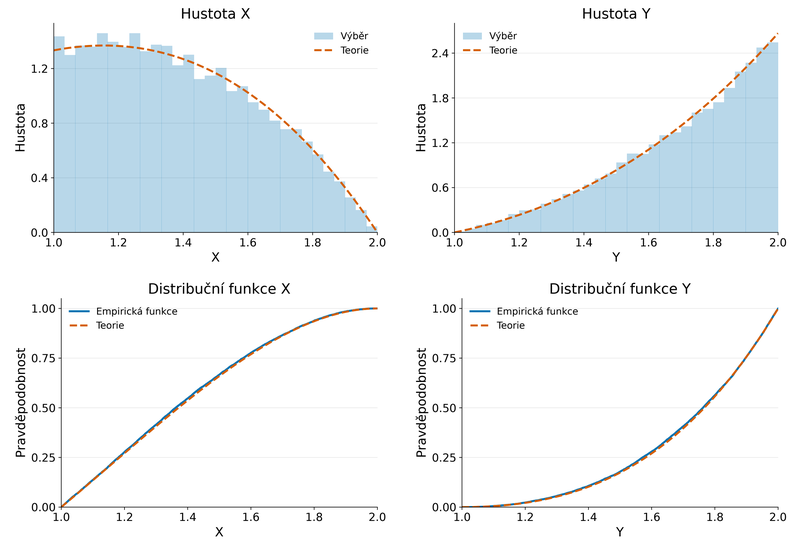
Shodná barevná škála. Na diagonále jsou rozptyly, mimo diagonálu kovariance. Výběrová matice používá jmenovatel $n - 1$.

$$S = \frac{1}{n-1}\sum_{i=1}^{n}(\mathbf{z}_i - \bar{\mathbf{z}})(\mathbf{z}_i - \bar{\mathbf{z}})^{\mathsf{T}}, \qquad \mathbf{z}_i = (x_i, y_i)^{\mathsf{T}}.$$

Charakteristika	Teorie	Odhad	95% interval
$\mathrm{E}[X]$	1.39259	1.38785	$(1.38381; 1.39190)$
$\mathrm{E}[Y]$	1.71852	1.71458	$(1.71098; 1.71819)$
$\mathrm{Var}(X)$	0.06069	0.06024	$(0.05886; 0.06167)$
$\mathrm{Var}(Y)$	0.04669	0.04782	$(0.04672; 0.04895)$
$\mathrm{Cov}(X, Y)$	0.02656	0.02691	—

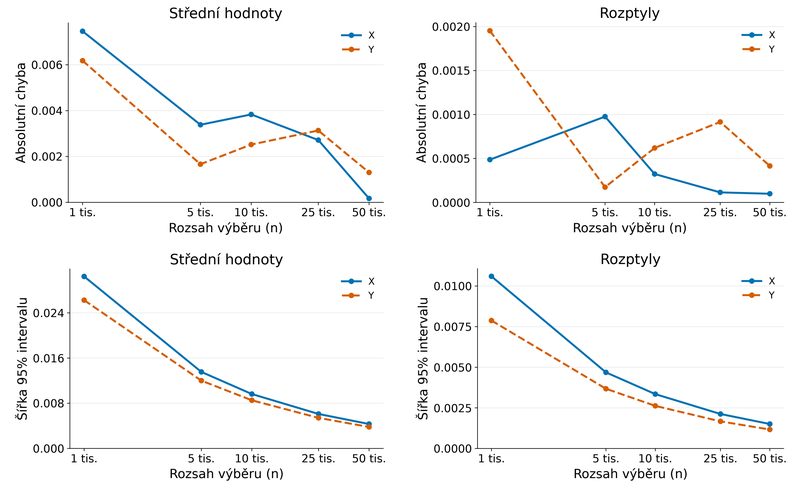
Technologie: Python, NumPy (generování a odhady), SymPy (přesné integrály), SciPy (kvantily), Matplotlib a Jupyter.

07 Výběr proti teoretickému rozdělení



Histogramy sledují teoretické hustoty. Největší absolutní odchylka empirické distribuční funkce od teorie je $D_X = 0.0124$, $D_Y = 0.0123$. Jde o popis odchylky v daném výběru, nikoli o výsledek testu hypotézy.

08 Vliv rozsahu výběru



Nahoře absolutní chyby; dole šířky 95% intervalů. Rozsahy $n = 1\,000, 5\,000, 10\,000, 25\,000, 50\,000$ jsou vnořené prefixy jednoho doplněného výběru; nejde o nezávislá opakování.

09 Závěry a využití

Více dat zmenšuje nejistotu. Intervaly pro průměry jsou při $n = 50\,000$ přibližně $7.0\times$ (X) a $6.9\times$ (Y) užší než při $n = 1\,000$. Chyba jednotlivého odhadu však nemusí klesat monotónně.
95% neznamená jistotu. V původním výběru oba intervaly pro průměry těsně míjejí teoretické hodnoty. Nominální spolehlivost se vztahuje k opakovanému výběru, nikoli k záruce pro jediný interval.
Omezení a využití. Intervaly pro rozptyly používají χ^2 postup určený pro normální data; zde jsou jen orientační. Program umožňuje kontrolu simulátoru a studium odhadů závislých veličin.